

Mission R&D PELVITRACK

nicolas.sutton-charani, Ethan Beuguel, Léna Pappo

January 2026

Abstract

Le projet PELVITRACK, coordonné aux Mines d'Alès, vise à prévenir la déchirure du périnée lors d'un accouchement. Dans un premier temps, différentes expériences ont été réalisées sur des périnés de cochons (l'étirement et la relaxation par exemple).

Ce projet vise à caractériser les dommages causés au périnée en utilisant des séquences d'images de périnée de porc qui sont successivement étirés et relâchés jusqu'à rupture totale. La progression de l'abîmement du périnée va être analysé avec différentes approches via des modèles prédictifs.

Les lésions périnéales étant assez difficiles à détecter visuellement avec précision au fil du temps, nous allons utiliser des labels réalisés par une étude technique qui a eu lieu l'année dernière. En résultera un pipeline prédictif où la rupture périnéale sera prédite le plus tôt possible à partir de descripteurs d'images (textures, indicateurs fractals, etc...). Les modèles seront évalués avec précision et/ou incertitude.

Abstract

The PELVITRACK project, coordinated by the École des Mines d'Alès, aims to prevent perineal tears during childbirth. Initially, various experiments were conducted on pig perineums (such as stretching and relaxation).

This project aims to characterize the damage caused to the perineum using image sequences of pig perineums that are successively stretched and released until complete rupture. The progression of perineal damage will be analyzed using various approaches via predictive models.

Since perineal lesions are quite difficult to detect visually with precision over time, we will use labels generated by a technical study conducted last year. This will result in a predictive pipeline where perineal rupture is predicted as early as possible based on image descriptors (textures, fractal indicators, etc.). The models will be evaluated in terms of accuracy and/or uncertainty.

Contents

1	Introduction	4
2	Méthodologie	5
2.1	Protocole expérimental et aquisition des données	5
2.2	Les modèles d'apprentissage automatique	5
2.3	Analyse exploratoire	7
3	Résultats	9
3.1	Performances globales	9
3.2	Analyse par séquence	10
3.3	Importance des descripteurs	10
4	Discussion	13
4.1	Interprétation générale des résultats	13
4.2	Influence des conditions expérimentales	13
4.3	Une situation très différente d'un accouchement réel	14
4.4	Limites de la labellisation	14
4.5	Apport des descripteurs de cycle mécanique	15
4.6	Perspectives	16
5	Conclusion	17
6	Bibliographie	19

1 Introduction

Pelvitrack est un projet européen ambitieux pour la prévention des déchirures du périnée. Il a pour objectif un «suivi en direct de l'évaluation de la santé du plancher pelvien permettant la prédiction, en temps réel, des traumatismes périnéaux» («PELVic Floor Evaluation live TRACKing – Real-time prediction of perineal trauma»). Il est porté par Anne-Sophie Caro et Sarah Iaquina, enseignantes-chercheuses à IMT Mines Alès au sein du LMGC (Laboratoire de Mécanique et Génie Civil).

Pelvitrack est un projet interdisciplinaire qui va rassembler 11 partenaires issus de 8 pays européens (France, Espagne, Italie, République Tchèque, Portugal, Royaume-Uni, Suisse), dont des institutions de recherche renommées, des universités, des hôpitaux et des PME. Parmi les 45 nouveaux projets sélectionnés par l'EIC Pathfinder [1] sur les 1100 déposés, Pelvitrack est l'un des trois seuls projets coordonnés en France.

Pour rentrer plus dans les détails du projet, il est nécessaire de savoir qu'il est actuellement impossible de prévenir les troubles du plancher pelvien, faute de pouvoir suivre ses modifications traumatiques. Pourtant, ces troubles peuvent être la cause de douleurs chroniques, d'incontinence urinaire ou fécale, ou encore de descente d'organes. Pour rappel, le plancher pelvien est situé dans la région inférieure du bassin entre l'os pubien à l'avant et le coccyx à l'arrière. Il soutient le système pelvien (utérus, vessie, rectum...) par l'intermédiaire de ses muscles et ligaments. Ses dysfonctionnements sont souvent la conséquence d'un accouchement traumatiques qui peut susciter des lacérations ou des déchirements au niveau des tissus entre le vagin et l'anus. Ils sont courants et surviennent dans 90% des accouchements par voie basse. Cependant, il n'atteignent pas toujours le même niveau de gravité. En prévention, les praticiens peuvent procéder à des incisions qui permettent de contrôler la localisation des déchirures. Cette technique peut toutefois s'avérer contre-productive si des incisions ont été réalisées alors qu'aucune déchirure n'aurait eu lieu car il est en effet difficile de détecter visuellement et en temps réel l'amorce d'une rupture tissulaire [2].

Le projet Pelvitrack vise à concevoir une solution clé en main pour surveiller en temps réel les déchirure périnéales pendant l'accouchement par voie basse. Cet outils révolutionnaire permettra la prévention systématique des déchirures périnéales, assurant un diagnostic plus précoce, un pronostic plus fiable et des soins plus efficaces.

Ce projet de grande ampleur a démarré il y maintenant un an et est prévu pour une durée de 4 ans. Au total, il a demandé un financement européen de 3,2M d'euros.

2 Méthodologie

2.1 Protocole expérimental et acquisition des données

Le jeu de données repose sur des essais de traction cyclique réalisés sur des périnées de porc, choisis comme modèle biologique pour simuler les sollicitations mécaniques subies lors d'un accouchement par voie basse. Le protocole a consisté à soumettre les échantillons à des cycles successifs d'étirement et de relaxation via un piston motorisé, jusqu'à la rupture complète des tissus. Cette campagne expérimentale a permis l'acquisition de 13 séquences vidéo haute résolution.

Dans le cadre d'une phase de prétraitement, ces séquences vidéo ont fait l'objet d'un échantillonnage temporel à une fréquence de 5 Hz afin de constituer une base de données d'images fixes. Un étiquetage (labellisation) a ensuite été effectué pour identifier l'instant critique de la rupture sur chaque séquence. Cette labellisation s'appuie sur l'analyse des courbes de force du piston : l'endommagement macroscopique est défini comme le point de bascule où l'amplitude des pics de force cesse de croître. Bien que l'initiation de l'endommagement précède probablement le pic de force (durant la phase ascendante), les limites de la détection visuelle sur les courbes mécaniques ont conduit à retenir ce critère conservateur. Cette étape de labellisation est fondamentale pour le développement ultérieur de modèles d'apprentissage supervisé.

2.2 Les modèles d'apprentissage automatique

Pour commencer, nous nous sommes intéressés aux différents modèles d'apprentissage automatique existant qui pourraient nous être utiles dans le cadre de notre projet.

Dans un premier temps il existe le kNN (K-Nearest Neighbors) [3]. Cet algorithme consiste à regarder les k plus proches voisins d'une donnée sur un graphe de manière à déterminer la valeur de la donnée elle-même. Si une grande proportion de voisins correspond à un certain état, il sera alors très probable que la donnée recherchée corresponde à cet état également. kNN mesure la distance entre les points : la valeur par défaut est euclidienne. Malheureusement, il n'y a pas de méthode efficace pour déterminer la bonne valeur de k . Il faut pour cela tester le modèle avec plusieurs valeurs de k et regarder sa précision (nombre de valeurs correctes de l'ensemble de tests) en fonction de cette valeur.




Figure 1: Modèle kNN




Figure 2: Modèle SVM

ode, développée dans les années 1990, est donc largement utilisée dans les problèmes de classification. Elle porte ce nom car les lignes adjacentes à l'hyperplan optimal sont appelées vecteur de support car ils passent par les points de données qui déterminent la marge maximale.

Il existe également le modèle d'arbre de décision [5]. Un arbre de décision est une structure arborescente semblable à un organigramme dans laquelle un nœud interne représente une caractéristique (ou un attribut), la branche représente une règle de décision et chaque nœud feuille représente le résultat. La complexité temporelle des arbres de décision dépend du nombre d'enregistrement et d'attributs dans les données fournies. C'est pour cela qu'il faut faire une sélection des meilleurs attributs à utiliser, réalisable notamment grâce la "règles de fractionnement" qui attribue un classement à chaque caractéristique.




Figure 3: Modèle d'arbre de décision

Les SVM sont plus performants avec des données de grande dimension mais cela dit, les arbres de décisions sont généralement plus rapide à entraîner (surtout avec des petits jeux de données) et ils sont aussi souvent plus facile à interpréter.




Figure 4: Modèle de la forêt aléatoire

Ensuite, nous avons le modèle SVM (machines à vecteurs de support) [4]. Les SVM sont des classificateurs qui cherchent à séparer des données en deux classes en traçant un hyperplan dans un espace à n dimensions. L'objectif principal des SVM est que la marge, soit la distance entre l'hyperplan et les points de données de chaque classe, soit la plus grande possible. Cela permet alors de généraliser à de nouvelles données et ainsi de réaliser des prédictions précises. Cette méthode,

Enfin, un autre modèle d'apprentissage automatique est la forêt aléatoire [6]. Cette méthode introduit un niveau supplémentaire d'aléa dans la construction des arbres, puisqu'à chaque nouveau nœud, la règle de décision est choisie en considérant uniquement un sous-ensemble de variables sélectionné aléatoirement. Cela réduit la corréla-

tion entre les arbres ce qui permet de diminuer la variance et ainsi de stabiliser les prédictions. Ainsi, les forêts aléatoires reposent sur quatre éléments essentiels :

- Les modèles élémentaires sont des arbres de décision ;
- Chaque arbre est construit à partir d'un échantillon aléatoire du jeu de données d'entraînement ;
- Lors de la construction d'un arbre, à chaque nœud de celui-ci, un sous-ensemble aléatoire de variables est sélectionné. La meilleure règle de décision est ensuite choisie uniquement parmi ces caractéristiques ;
- Les prédictions de tous les arbres sont combinées. On procède généralement à la moyenne – ou la médiane – des prédictions dans le cas de la régression, et au vote majoritaire dans le cas de la classification.

Ce modèle est assez robuste car il possède une propriété importante : l'erreur de généralisation diminue à mesure que le nombre d'arbres augmente et converge vers une valeur constante. Cela signifie qu'un grand nombre d'arbres ne dégrade pas la qualité du résultat. En revanche, une forêt aléatoire peut souffrir de surajustement si ses autres hyperparamètres sont mal choisis (des arbres trop profonds par exemple).

Nous avons également du choisir une technique de validation pour pouvoir évaluer notre modèle. Ces techniques permettent en effet d'estimer dans quelle mesure un modèle se généralisera à un ensemble de données indépendantes, qui n'a pas été utilisé lors de la formation du modèle. Pour cela, nous avons choisi la méthode *Leave One Out*. Cette technique est un cas spécifique de validation croisée où chaque observation est utilisée une fois comme un ensemble de test tandis que les observations restantes forment l'ensemble d'apprentissage. Cela permet d'avoir un biais minimal étant donné que le modèle est testé dans des conditions presque identiques à celles d'un entraînement sur le dataset complet. Cette approche est donc particulièrement bénéfique lorsqu'il s'agit de petits ensembles de données, ce qui est notre cas car nous n'avons que 13 vidéos sur lesquelles nous appuyer [7].

2.3 Analyse exploratoire

Dans un premier temps, nous nous sommes attardés sur les images statiques plus que sur les vidéos. Pour chaque image d'une vidéo nous avons calculé la moyenne ainsi que l'écart type du niveau de gris de l'image. Pour cela, nous avons transformé l'image en une matrice de 400x400, dont chaque valeur représente le niveau de gris du pixel. Nous avons observé à l'œil nu que l'image devenait beaucoup plus sombre lorsque le périnée se déchirait car celui-ci est blanc sur fond noir. Et en effet, nous avons remarqué sur des graphiques que cela était

très marqué surtout en regardant l'écart type du niveau de gris (beaucoup plus qu'avec la moyenne) qui chutait considérablement au moment de la déchirure.

Nous avons donc voulu réaliser une classification binaire en décidant, dans un premier temps que lorsque l'écart type du niveau de gris de l'image évoluait de plus de 5%, cela signifiait que le périnée était déchiré. Nous sommes cependant revenu sur cette décision car nous nous sommes aperçu que cela ne fonctionnait que pour un nombre réduit de vidéos et pas pour toutes. En effet, pour que cela fonctionne, il faudrait que le périnée se déchire entièrement dès la première entaille ce qui est rarement le cas. Il a plutôt tendance à se déchirer légèrement (fissure qui est parfois compliquée à distinguer à l'œil nu) avant d'attendre quelques extensions de piston en plus pour se déchirer totalement.

Nous avons aussi voulu essayer un nouveau descripteur qui est le HOG. Ce descripteur permet à l'apparence et à la forme locale d'un objet dans une image d'être décrites par la distribution de l'intensité du gradient ou la direction des contours. Dans un premier temps, nous avons réussi à décrire l'image avec ce descripteur mais nous n'avons pas réussi à l'interpréter et à l'utiliser pour définir si le périnée était déchiré ou non. Il a finalement été écarté car il est peu robuste aux déformations texturales non structurées des tissus mous.

3 Résultats

3.1 Performances globales

Le protocole Leave-One-Video-Out a été appliqué sur les 13 séquences vidéo disponibles. À chaque itération, le modèle est entraîné sur 12 vidéos et évalué sur la 13^{ème}, ce qui garantit qu’aucune information de la séquence de test n’est utilisée lors de l’entraînement. Les résultats obtenus indiquent une accuracy moyenne de 91,3% et un F1-score moyen de 91,5%. Ces chiffres sont encourageants compte tenu de la faible taille du jeu de données (13 séquences) et de la difficulté intrinsèque du problème, où la rupture peut être visuellement difficile à distinguer dans les premières frames qui la suivent.

Le tableau 3.1 présente les performances détaillées pour chaque séquence. Le retard de détection est défini comme $\Delta t = t_{\text{détecté}} - t_{\text{vrai}}$ et exprimé en frames analysées ainsi qu’en secondes selon la conversion $\Delta t_s = \Delta t \times \text{FRAME_SKIP} / \text{FPS} = \Delta t \times 5 / 25$. Une valeur négative indique que le modèle a détecté la rupture avant le label de référence, une valeur positive indique une détection tardive.

Vidéo	Accuracy	F1-score	Frame réelle	Frame détectée	Retard (fr.)	Retard (s)
C1MA	0,993	0,994	1340	1315	−25	−1, 0
C1VA	0,949	0,961	1574	1829	+255	+10, 2
C1VB	0,872	0,900	1607	2304	+697	+27, 9
C2MA	0,822	0,840	393	590	+197	+7, 9
C3MA	0,918	0,932	972	1197	+225	+9, 0
C3MB	0,991	0,991	1074	1054	−20	−0, 8
C3MC	0,915	0,916	692	822	+130	+5, 2
C3MD	0,781	0,756	687	459	−228	−9, 1
C3SA	0,841	0,806	2031	1550	−481	−19, 2
C3SB	0,933	0,936	2006	1746	−260	−10, 4
C3VA	0,979	0,980	312	299	−13	−0, 5
C3VB	0,973	0,983	537	606	+69	+2, 8
C3VC	0,902	0,905	356	290	−66	−2, 6
Moyenne	0,913	0,915	—	—	+36, 9	+1, 5
Min	0,781	0,756	—	—	−481	−19, 2
Max	0,993	0,994	—	—	+697	+27, 9

Table 1: Résultats du protocole Leave-One-Video-Out pour les 13 séquences vidéo.

Sur les 13 séquences, 4 atteignent une accuracy supérieure à 97%, 5 se situent entre 90% et 97%, et 4 restent en dessous de 90%. Le retard moyen de +36,9 frames correspond à environ +1, 5 secondes à 25 fps, ce qui reste compatible avec une utilisation en contexte d’alerte précoce, sous réserve d’une optimisation pour le traitement en temps réel.

3.2 Analyse par séquence

En observant les résultats séquence par séquence, on peut distinguer trois groupes de comportement.

Séquences bien détectées (accuracy > 97%). Les séquences C1MA (99,3%), C3MB (99,1%) et C3VA (97,9%) obtiennent les meilleures performances avec des retards très faibles, respectivement -25 , -20 et -13 frames, soit moins d’une seconde. Ces trois séquences ont en commun des cycles mécaniques réguliers et bien marqués dans le signal de luminosité, avec un nombre de cycles suffisant (3 à 6 cycles détectés) pour que le modèle construise un contexte temporel solide. La probabilité prédite monte de façon nette et monotone au moment de la rupture, ce qui permet au pipeline de détection par point d’inflexion de se déclencher précisément.

Séquences correctement détectées (accuracy entre 90% et 97%). La majorité des séquences se situent dans cette plage, avec des F1-scores compris entre 0,906 et 0,983. Pour C1VA (94,9%), la détection intervient 255 frames après le label, ce qui s’explique par un signal de luminosité progressif : la rupture ne produit pas de changement brusque immédiatement visible, et le modèle attend un niveau de certitude suffisant avant de déclencher la détection. Pour C3SB (93,3%), la détection précoce de -260 frames s’explique probablement par le fait que la séquence présente 7 cycles, ce qui donne au modèle beaucoup de contexte et lui permet de reconnaître les signes précurseurs de la rupture avant même que le label mécanique ne soit atteint.

Séquences difficiles (accuracy < 90%). Trois séquences présentent des performances plus faibles : C1VB (87,2%), C2MA (82,2%) et C3MD (78,1%). Pour C2MA, la rupture survient très tôt dans la séquence, à la frame 393 (soit 15,7 secondes), après seulement 3 cycles mécaniques détectés. Le modèle dispose d’un contexte temporel insuffisant pour exploiter pleinement les descripteurs de cycle, ce qui entraîne une détection tardive de $+197$ frames. Pour C1VB, le retard de $+697$ frames (soit 27,9 secondes) est le plus important de l’ensemble. Pour C3MD (78,1% d’accuracy, F1 de 0,756), une détection très précoce est observée à -228 frames, ce qui génère 228 faux positifs dans la matrice de confusion. Ce cas illustre la limite du modèle lorsque le signal visuel pré-rupture ressemble à celui d’autres séquences en phase de rupture.

3.3 Importance des descripteurs

L’analyse des importances de features fournies par le modèle GradientBoosting révèle une hiérarchie très stable sur l’ensemble des 13 folds. Le tableau 3.3 présente les importances moyennes des principaux descripteurs.

Descripteur	Description	Importance moyenne
<code>img1_rise</code> (r_t)	Montée de luminosité depuis le creux récent	62,4%
<code>laplacian_var</code> ($\mathcal{L}_t$)	Variance du Laplacien (netteté)	11,9%
<code>diff_mean</code> (d_t)	Différence absolue inter-frames	9,8%
<code>cycle_period</code> (T_k)	Durée du cycle mécanique précédent	6,3%
<code>pos_rel</code> (ρ_t)	Position relative dans la vidéo	1,4%
<code>img1</code> (μ_t)	Luminosité moyenne globale	1,2%
<code>zone_bl</code>	Luminosité quadrant bas-gauche	0,7%
Autres (13 descripteurs)	—	6,3%

Table 2: Importance moyenne des descripteurs sur les 13 folds du protocole Leave-One-Video-Out.

Le descripteur `img1_rise`, défini comme $r_t = \mu_t - \min_{s \in [t-14, t]}(\mu_s)$, est de loin le plus discriminant avec une importance moyenne de 62,4%. Il mesure de combien la luminosité a monté depuis son creux le plus récent sur une fenêtre de 15 frames. Ce descripteur capture très efficacement les fins de course du piston, instants où le tissu est au maximum de son étirement et où la rupture est susceptible de se produire. Son importance élevée confirme l’intuition à l’origine de sa conception : la rupture périnéale survient toujours dans une phase de montée rapide de la luminosité.

Le deuxième descripteur le plus important est la variance du Laplacien (`laplacian_var`), avec une importance moyenne de 11,9%. Ce descripteur mesure la netteté globale de l’image. L’apparition d’une fissure dans le tissu crée de nouveaux contours brusques qui se traduisent par une augmentation de la variance du Laplacien. C’est donc un indicateur direct de changement de texture, complémentaire à `img1_rise` qui capte la dynamique temporelle.

La différence absolue inter-frames (`diff_mean`) arrive en troisième position avec 9,8%. Ce descripteur quantifie le mouvement global entre deux frames consécutives. Il augmente naturellement lors des phases d’étirement rapide du piston et chute au moment de la rupture, lorsque le tissu ne résiste plus et que le mouvement se stabilise. La période du cycle mécanique (`cycle_period`) contribue à hauteur de 6,3% et fournit au modèle une information sur le rythme de sollicitation, lui permettant de distinguer les fins de cycle normales des fins de cycle anormales où la rupture intervient.

À l’inverse, les descripteurs de bas niveau comme les statistiques glissantes (`roll_std_img1`, `roll_std_diff`) et les descripteurs de texture fine (`edge_mean`, `edge_std`) contribuent très peu à la décision finale, avec des importances individuelles inférieures à 0,5%. Cela suggère que ces descripteurs apportent une information redondante par rapport aux descripteurs dominants, et qu’une version allégée du pipeline pourrait s’en passer sans perte significative de performance.

Ces résultats soulignent l’importance cruciale des descripteurs temporels liés

à la dynamique du signal de luminosité et au cycle mécanique, par rapport aux descripteurs purement spatiaux ou texturaux. Cela confirme que la rupture périnéale est avant tout un phénomène dynamique, qui se manifeste par une évolution temporelle du signal vidéo plutôt que par une signature spatiale fixe dans une seule image.

4 Discussion

4.1 Interprétation générale des résultats

Les résultats obtenus sont encourageants et démontrent qu'il est possible de détecter automatiquement la rupture périnéale à partir d'une séquence vidéo, avec une accuracy moyenne de 91,3% et un F1-score de 91,5% sur 13 vidéos. Ces chiffres sont d'autant plus intéressants que le modèle n'a jamais vu la vidéo testée lors de son entraînement, ce qui constitue une condition d'évaluation réaliste et honnête.

Cela dit, la variabilité des résultats entre les vidéos, qui va de 78,1% à 99,3% d'accuracy, montre qu'il reste des cas difficiles à traiter. Cette variabilité n'est pas surprenante : les 13 expériences, bien que réalisées dans des conditions globalement similaires, présentent des différences qui ont un impact réel sur la détection. Nous allons détailler ces différences dans les sous-sections suivantes.

4.2 Influence des conditions expérimentales

Les expériences ont été réalisées sur des périnées de porc soumis à des cycles successifs d'étirement et de relâchement via un piston motorisé, jusqu'à rupture totale du tissu. Bien que le protocole soit le même pour toutes les séquences, nous avons observé des différences importantes d'une expérience à l'autre qui expliquent en grande partie les écarts de performance.

La durée de la séquence et le nombre de cycles. Certaines séquences sont très longues avec de nombreux cycles avant la rupture (C1VB : 11 cycles, C1VA : 8 cycles), tandis que d'autres sont très courtes avec peu de cycles (C3VC : 1 seul cycle, C3VA : 2 cycles, C2MA : 3 cycles). Or, les descripteurs de cycle mécanique que nous avons introduits, comme la période du cycle précédent ou la montée de luminosité depuis le creux récent, nécessitent d'observer plusieurs cycles pour être pleinement informatifs. Pour C2MA par exemple, la rupture survient après seulement 3 cycles et 75 secondes de vidéo, ce qui laisse très peu de contexte au modèle pour apprendre la dynamique normale du piston avant de devoir détecter la rupture.

La nature de la rupture. D'une expérience à l'autre, la rupture ne se produit pas de la même façon. Pour certaines séquences, la déchirure est brusque et provoque un changement visuel net et immédiat. Pour d'autres, le tissu se fissure légèrement d'abord, avant de se déchirer totalement plusieurs cycles plus tard. Ce deuxième cas est beaucoup plus difficile à détecter car la première fissure est parfois imperceptible à l'œil nu, et le signal vidéo ne présente pas de rupture franche. C'est ce qui explique le retard important de C1VB (+697 frames, soit 140 secondes) : la première fissure n'est pas suffisamment visible pour déclencher la détection, et le modèle attend que le changement soit plus marqué dans le signal de luminosité.

Les conditions d’éclairage et de positionnement. Même si les expériences ont été réalisées dans un environnement contrôlé, de légères variations d’éclairage ou de positionnement du tissu par rapport à la caméra peuvent modifier les valeurs absolues des descripteurs d’intensité. C’est pourquoi nous avons appliqué une normalisation z-score par vidéo, afin que chaque descripteur soit ramené à une échelle comparable quelle que soit la séquence. Cela permet au modèle d’être moins sensible à ces variations, mais ne les élimine pas complètement.

4.3 Une situation très différente d’un accouchement réel

Il est important de souligner que les conditions expérimentales dans lesquelles nous avons travaillé sont très éloignées de celles d’un accouchement en milieu hospitalier. Cette différence est fondamentale et doit être gardée à l’esprit pour bien comprendre les limites de notre approche.

Dans nos expériences, le tissu est un périnée de porc maintenu sur un piston motorisé dans un environnement contrôlé, avec un éclairage stable, un fond uniforme, et aucune perturbation extérieure. La caméra est fixe, positionnée de façon optimale, et filme un seul tissu bien visible. La rupture est provoquée de façon mécanique et répétée selon un protocole précis. Ce sont des conditions idéales pour un modèle d’apprentissage automatique.

Un accouchement par voie basse est une situation radicalement différente. Le périnée est entouré d’autres tissus, baigné dans des fluides biologiques (sang, liquide amniotique) qui modifient fortement l’aspect visuel de la scène. L’éclairage en salle d’accouchement est variable et pas toujours optimal pour une caméra. La zone à observer est en mouvement constant, et d’autres instruments ou les mains du praticien peuvent obstruer partiellement le champ de vision. De plus, la déchirure périnéale lors d’un accouchement ne suit pas un protocole répété et régulier comme un piston motorisé : elle se produit de façon imprévisible, sous l’effet des contractions et de la progression du bébé.

Ces différences signifient que notre modèle, même s’il atteint une bonne accuracy sur les données expérimentales, ne pourrait pas être utilisé directement en salle d’accouchement sans une phase d’adaptation importante. Il faudrait notamment le réentraîner sur des données acquises dans des conditions cliniques réelles, avec des images de périnées humains dans des conditions d’éclairage et de visualisation proches de celles d’un bloc obstétrical. Cette étape devra être prévue dans les phases ultérieures du projet Pelvitrack.

4.4 Limites de la labellisation

Une autre source d’erreur importante ne vient pas du modèle lui-même, mais de la façon dont les données ont été labellisées. Pour rappel, le label de rupture a été défini comme le point où l’amplitude des pics de force du piston cesse de

croître. Ce critère mécanique est pratique à utiliser, mais il ne correspond pas exactement au moment où la rupture devient visible dans la vidéo.

En effet, l’initiation réelle de l’endommagement précède vraisemblablement ce point. La première microfissure apparaît durant la phase ascendante de la force, avant que le pic ne soit atteint. Mais cette fissure est souvent trop petite pour être détectée visuellement sur les courbes de force, ce qui a conduit à retenir un critère plus conservateur. Concrètement, cela signifie que le label indique «il y a eu rupture à ce moment» alors que la vraie rupture a commencé un peu avant.

Cette approximation a des conséquences directes sur nos résultats. Certaines détections que nous qualifions de précoces pourraient en réalité correspondre à une détection plus fidèle à la vraie initiation visuelle de la rupture. C’est notamment une hypothèse plausible pour C3SA (−481 frames) et C3SB (−260 frames), où le modèle détecte un changement visuel significatif bien avant que le critère mécanique ne soit atteint. Dans ces cas, il est difficile de savoir si le modèle fait une erreur ou s’il détecte quelque chose que le label a manqué.

Pour améliorer la qualité de la labellisation, une piste serait de coupler le critère mécanique avec une annotation visuelle manuelle des premières frames présentant une modification de texture du tissu. Cela demande plus de travail mais permettrait d’obtenir un label plus fidèle à la réalité optique et d’évaluer le modèle de façon plus juste.

4.5 Apport des descripteurs de cycle mécanique

L’un des apports principaux de ce travail est l’introduction de descripteurs encodant la position temporelle dans le cycle mécanique du piston. L’idée de départ est simple : nous avons observé que la rupture survient toujours vers la fin d’un cycle, lorsque le tissu est au maximum de son étirement. En donnant au modèle des informations sur où en est la séquence dans le cycle courant, nous lui permettons de mieux distinguer les fins de cycle normales des fins de cycle anormales où la rupture intervient.

Les résultats confirment cette intuition. Le descripteur `img1_rise`, qui mesure de combien la luminosité a monté depuis son creux le plus récent sur les 15 dernières frames, est de loin le plus important avec 62,4% d’importance moyenne. Ce descripteur est naturellement élevé en fin de cycle, ce qui en fait un indicateur très efficace de la phase d’étirement maximal. La période du cycle précédent contribue quant à elle à hauteur de 6,3%, ce qui montre que le modèle apprend effectivement à tenir compte du rythme du piston pour affiner sa décision.

Sans ces descripteurs, le modèle aurait dû se reposer uniquement sur des descripteurs instantanés, qui peuvent être trompeurs : un pic de luminosité en

milieu de cycle peut ressembler visuellement à un pic de luminosité pré-rupture. L'information contextuelle sur le cycle permet de lever cette ambiguïté.

4.6 Perspectives

Ce travail constitue une première étape dans le développement d'un système de détection automatique de la rupture périnéale. Plusieurs pistes d'amélioration peuvent être envisagées pour la suite.

La première et la plus importante est d'augmenter le jeu de données. Avec seulement 13 séquences, le modèle ne peut pas apprendre à gérer toute la variabilité des situations possibles. L'ajout de nouvelles séquences, idéalement dans des conditions variées et sur des tissus différents, permettrait d'améliorer considérablement la robustesse du modèle.

La deuxième piste est d'utiliser une région d'intérêt centrée directement sur la zone du tissu à risque. Actuellement, les descripteurs sont calculés sur l'image entière, ce qui dilue les changements locaux liés à la fissure dans le signal global. En concentrant l'analyse sur la zone concernée, on pourrait rendre les descripteurs beaucoup plus sensibles aux premières manifestations de la rupture.

Enfin, l'intégration du pipeline dans un système temps réel reste l'objectif final du projet Pelvitrack. Cela nécessiterait d'optimiser le temps de calcul par frame et de valider le système sur des données humaines acquises en conditions cliniques réelles, avec un éclairage variable, la présence de fluides biologiques et le mouvement naturel de la scène lors d'un accouchement.

5 Conclusion

Ce travail s'inscrit dans le cadre du projet européen Pelvitrack, dont l'objectif est de développer un système capable de détecter en temps réel les déchirures périnéales lors d'un accouchement par voie basse. Ces déchirures surviennent dans 90% des accouchements par voie basse et peuvent entraîner des conséquences graves pour la patiente, comme des douleurs chroniques, de l'incontinence ou des descentes d'organes. Pourtant, il est aujourd'hui très difficile pour un praticien de détecter visuellement et en temps réel l'amorce d'une rupture tissulaire. Notre contribution dans ce projet a consisté à développer et évaluer un pipeline de détection automatique de cette rupture à partir de séquences vidéo, en utilisant des techniques d'apprentissage automatique supervisé.

Dans un premier temps, nous nous sommes intéressés à l'analyse exploratoire des images. Nous avons observé que l'écart-type du niveau de gris chutait considérablement au moment de la déchirure, ce qui constituait un premier indicateur prometteur. Cependant, cette approche simple ne fonctionnait que pour un nombre réduit de vidéos, car la rupture périnéale est rarement totale et immédiate. Le tissu a plutôt tendance à se fissurer légèrement avant de se déchirer complètement au fil des cycles suivants. Nous avons également exploré le descripteur HOG, qui n'a finalement pas été retenu car il est peu robuste aux déformations non structurées des tissus mous.

Nous avons ensuite développé un pipeline plus complet, basé sur l'extraction de 20 descripteurs par frame regroupés en quatre catégories : des descripteurs d'intensité globale, des descripteurs de texture et de contour, des descripteurs de mouvement inter-frames, et des descripteurs de position dans le cycle mécanique du piston. Ces derniers constituent l'apport original de notre approche. En observant que la rupture survient toujours vers la fin d'un cycle, lorsque le tissu est au maximum de son étirement, nous avons donné au modèle une information sur la phase courante du cycle, ce qui lui permet de mieux distinguer les fins de cycle normales des fins de cycle anormales où la rupture intervient. Le modèle retenu est un Gradient Boosting, entraîné avec une pondération adaptée pour compenser le déséquilibre entre frames normales et frames de rupture, et évalué selon un protocole Leave-One-Video-Out sur les 13 séquences disponibles.

Les résultats obtenus sont encourageants. Nous atteignons une accuracy moyenne de 91,3% et un F1-score moyen de 91,5% sur l'ensemble des 13 séquences. Sur ces 13 vidéos, 9 atteignent une accuracy supérieure à 90%, et 4 dépassent 97%. Le retard moyen de détection est de +1,5 seconde, ce qui reste compatible avec une utilisation en contexte d'alerte précoce. L'analyse des importances de features a montré que le descripteur le plus discriminant est `img1_rise`, qui mesure la montée de luminosité depuis le creux récent. La variance du Laplacien et la différence absolue inter-frames complètent ce trio de descripteurs dominants, avec des importances respectives de 11,9% et 9,8%.

Nous avons également identifié les cas les plus difficiles pour notre modèle. Les séquences courtes avec peu de cycles avant la rupture, comme C2MA (3 cycles, rupture à 47 secondes), donnent moins de contexte temporel au modèle et entraînent des retards de détection plus importants. À l'inverse, certaines séquences présentent une détection très précoce, ce qui peut s'expliquer en partie par les limites de la labellisation : le critère mécanique retenu pour définir la rupture ne correspond pas exactement au moment où le changement devient visible dans la vidéo, ce qui introduit un biais difficile à corriger sans une méthode de référence plus précise.

Plusieurs limites importantes doivent cependant être rappelées avant d'envisager une application clinique. Tout d'abord, les expériences ont été réalisées dans des conditions très contrôlées, sur des périnées de porc, avec un éclairage stable, un fond uniforme et aucune perturbation extérieure. Ces conditions sont très éloignées de celles d'un accouchement réel, où la présence de fluides biologiques comme le sang et le liquide amniotique, un éclairage variable, le mouvement naturel de la patiente et la présence d'instruments dans le champ de vision rendraient la détection beaucoup plus difficile. Ensuite, avec seulement 13 séquences disponibles, le modèle ne peut pas apprendre à gérer toute la variabilité des situations possibles. Enfin, le pipeline fonctionne actuellement en mode différé et n'a pas encore été optimisé pour un traitement en temps réel.

La prochaine étape logique serait d'augmenter le jeu de données, d'utiliser une région d'intérêt centrée directement sur la zone du tissu à risque plutôt que l'image entière, et de tester le pipeline sur des données acquises dans des conditions plus proches d'un bloc obstétrical. Ces travaux s'inscrivent dans la continuité du projet Pelvitrack, qui prévoit à terme de valider le système sur des données humaines et de l'intégrer dans un dispositif utilisable en temps réel en salle d'accouchement, avec pour objectif final d'aider les praticiens à prévenir les déchirures périnéales et à améliorer la prise en charge des patientes lors de l'accouchement.

6 Bibliographie

References

- [1] IMT Mines Alès. *PELVITRACK : un projet européen ambitieux pour la prévention des déchirures du périnée*. URL: <https://www.imt-mines-ales.fr/actualites/pelvitrack-un-projet-europeen-ambitieux-pour-la-prevention-des-dechirures-du-perinee>.
- [2] Anne-Sophie Caro et Sarah Iaquina. *Mieux anticiper les déchirements du périnée*. URL: <https://theconversation.com/mieux-anticiper-les-dechirements-du-perinee-220493>.
- [3] Adam Shafi. *Classification par K-Nearest Neighbors (KNN) avec scikit-learn*. URL: <https://www.datacamp.com/fr/tutorial/k-nearest-neighbor-classification-scikit-learn>.
- [4] Eda KavlaKoglu. *Que sont les machines à vecteurs de support (SVM) ?* URL: <https://www.ibm.com/fr-fr/think/topics/support-vector-machine#684929714>.
- [5] Avinash Navlani. *Classification par arbre de décision dans le tutoriel Python*. URL: <https://www.datacamp.com/fr/tutorial/decision-tree-classification-python>.
- [6] *Présentation formelle des algorithmes > La forêt aléatoire*. URL: https://inseefrlab.github.io/DT_methodes_ensemblistes/chapters/chapter2/3-random_forest.html.
- [7] FasterCapital. *Méthode Leave One Out : Leave One Out : l'approche Jackknife de la validation*. URL: <https://fastercapital.com/fr/contenu/Methode-Leave-One-Out---Leave-One-Out---l-approche-Jackknife-de-la-validation.html>.